

Estadística parte 1

Curso de Investigación en Radiología

Objetivos


- Entender las diferencias del análisis de datos numéricos y categóricos.
- Uso de principales estadísticas en análisis descriptivo (tendencia central, variabilidad y correlación).
- Conceptos de muestreo y teorema del límite central.
- Distribución de probabilidades.
- Pruebas de normalidad.
- Pruebas de hipótesis:
 - Paramétricas.
 - No paramétricas.
- Introducción a regresión lineal.

Variables

Table 1: Types of Data

Data Subtypes	Definition	Examples
Numerical		
Continuous interval	Numerical value with equal differences between each unit	Temperature in °C
Continuous ratio	Numerical value with equal differences between each unit and have meaningful ratio	Signal-to-noise ratio
Discrete (count)	Numerical values that are only integer	Number of tumors in an organ Ionizing radiation dose
Categorical		
Dichotomous	Only two categories	Female or male
Nominal	More than two categories without meaningful order	Imaging modality (US, CT, MR)
Ordinal	More than two categories with logical order	TNM tumor staging


Datos poblacionales y muestrales



“Estadísticos poblacionales”:

- Media
- Mediana
- Moda
- Desviación estándar
- Min
- Max
- Percentiles
- Rango Intercuartílico
- Skewness
- Kurtosis

Datos poblacionales y muestrales




Medidas estadísticas

Medidas de tendencia central	Medidas de posición	Medidas de dispersión	Medidas de asimetría
Media	Mínimo	Varianza	Skewness
Mediana	Máximo	Desviación estándar	Curtosis
Moda	Percentiles	Coeficiente de variación	
		Rango (max - min)	
		IQR (rango intercuartílico)	


Percentiles: Calcular el percentil 40

Datos = [16, 10, 12, 8, 15, 18, 20, 9, 11, 1, 13, 17, 9, 10, 14]




Datos ordenados: Datos = [1, 8, 9, 9, 10, 10, 11, 12, 13, 14, 15, 16, 17, 18, 20]

- Posición = $N \times \text{percentil} / 100$
- Posición = $15 \times 40 / 100$
- Posición = 6 (6º posición en los datos)




Percentiles: Calcular el percentil 40

Datos = [16, 10, 12, 8, 15, 18, 20, 9, 11, 1, 13, 17, 9, 10, 14]




Datos ordenados: Datos = [1, 8, 9, 9, 10, 10, 11, 12, 13, 14, 15, 16, 17, 18, 20]

- Posición = $N \times \text{percentil} / 100$
- Posición = $15 \times 40 / 100$
- Posición = 6 (6º posición en los datos)




Herramientas de visualización: Boxplot




Herramientas de visualización: histograma

Valor	Recuento
1	1
2	1
4	1
5	1
6	1
7	2
8	3
10	1
12	1
14	1
15	3
16	3
18	1

16	18	6	7	7	14	15	4	8	12	5	2	8	16	8	1	10	15	16	15
----	----	---	---	---	----	----	---	---	----	---	---	---	----	---	---	----	----	----	----






Herramientas de visualización: histograma





Curtosis & Skewness

Curtosis: índice de apuntalamiento




Skewness: índice de asimetría


Distribución de los datos



- $X \sim \text{Normal}(\mu, \sigma)$.
- $\mu = 25$.
- $\sigma = 3$.





Distribución de los datos




- Verde: $\mu = 22$; $\sigma = 2$
- Rojo: $\mu = 25$; $\sigma = 3$
- Azul: $\mu = 27$; $\sigma = 6$

Distribución de los datos




Otras distribuciones


Distribución Normal




Distribución LogNormal




Distribución Gamma




Distribución Beta




Distribución Exponencial



Distribución Binomial





Ejemplo distribución de valores




Tumor papilar:
Media: 74.94
Desviación Std: 27.052
Kurtosis: 2.87
Skewness: -1.195

Distribución pixeles tumor papilar




Células claras:
Media: 74.024
Desviación Std: 36.109
Kurtosis: -0.516
Skewness: -0.411


Distribución valores pixeles tumor células claras




¿Como saber si mis datos son Normales?




- Media ~ Mediana ~ Moda
- Kurtosis = 3 (índice de apuntalamiento)
- Skewness = 0 (coef de asimetría).




¿Como saber si mis datos son Normales?



- Skewness: -0.653
- Kurtosis: 3.239
- Media: 0.769
- Mediana: 0.784
- Moda: 0.813









- Skewness: 0.903
- Kurtosis: 4.261
- Media: 0.862
- Mediana: 0.805
- Moda: 0.720




- Skewness: 0.0025
- Kurtosis: 2.980
- Media: 3.999
- Mediana: 3.998
- Moda: 4.001

Quantile - Quantile Plot (QQ-Plot)



Test de Shapiro Wilk








- Hipótesis Nula (H_0):
 - Datos provienen de distribución Normal.
- Hipótesis Alternativa (H_a):
 - Datos no provienen de distribución Normal.
- Valor p menor al nivel de significancia definido (p.ej: <0.05) **rechaza la hipótesis nula.**

$$W = \frac{\left(\sum_{i=1}^n a_i x_{(i)} \right)^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

4 muestras aleatorias de 10 personas, sin reemplazo

Problema:



Población X -> 100.000 personas
Parámetros μ y σ desconocidos

Problema:

Población X -> 100.000 personas

Parámetros μ y σ :


- $\mu = 90,06$
- $\sigma = 12,82$

Muestras aleatorias de X

Parámetros μ y σ estimados:

- media muestral = 90,61
- SD muestral = 12,58

4 muestras aleatorias de 10 personas, sin reemplazo




“Ley de los grandes números”

Teorema del límite central


- Cada vez que obtengo una muestra aleatoria, voy a obtener un resultado diferente.
- Las medias muestrales tienden a distribuir normal.

$$E(\hat{X}) = \mu$$

Error estándar: $SE(\hat{X}) = \frac{\sigma}{\sqrt{n}}$



Teorema del Límite Central: intervalos de confianza



Prueba de Hipótesis

- Metodología que evalúa si una condición o afirmación es correcta respecto a la evidencia disponible de los datos.
- Se contrastan dos hipótesis:
 - Hipótesis nula (H_0): “Hipótesis conservadora” de igualdad o no efecto.
 - Hipótesis alternativa (H_a o H_1): Es el enunciado que se quiere demostrar que es verdadero.
- Prueba de Hipótesis acepta o rechaza Hipótesis Nula.

Prueba de Hipótesis

- Supuestos que se deben cumplir:
 - Independencia entre las variables.
 - Normalidad para pruebas paramétricas.
 - Homoscedasticidad (igualdad de varianza).

Prueba de Hipótesis

¿Cuál es mas grave?

- Errores:

- **Error tipo I:** Rechazar la hipótesis nula, siendo correcta (Falso Positivo).

α : probabilidad de cometer error tipo I.

- **Error tipo II:** Aceptar la hipótesis nula, siendo verdadera la hipótesis alternativa (Falso Negativo).

β : probabilidad de cometer error tipo II.

Prueba de Hipótesis

- Receta:
 - Definir Hipótesis Nula e Hipótesis alternativa.
 - Identificar prueba estadística adecuada según características de mis datos.
 - Determine el nivel de significancia (valor para alfa)
 - Basado en el conjunto de datos calcule el estadístico de prueba.
 - Conclusión.



Prueba de Hipótesis: ejemplo 1

- Una máquina embasadora debería llenar las botellas con 500 cc.
- Se realiza muestra de 49 botellas y se obtiene:
 - Media muestral ($\hat{X}$): 496 cc.
 - Desviación estándar muestral (s): 14 cc.



Prueba de Hipótesis: ejemplo 1

- ¿La máquina embasadora está realmente sirviendo menos refresco?
- **Hipótesis nula:**
 - $\mu = 500$
- **Hipótesis alternativa:**
 - $\mu < 500$
- **Nivel de significancia (alfa):**
 - 1%, 3%, 5%, 10%?



Prueba de Hipótesis: ejemplo 1

- Error estándar:

- $SE = \frac{14}{\sqrt{49}} = \frac{14}{7} = 2$


- Estadístico de prueba:

- $t = \frac{\bar{x} - \mu}{\frac{s}{\sqrt{n}}} = \frac{496 - 500}{2} = -2$

- Valor p = 0,02275

- $IC_{95\%} = \hat{X} \pm t_{0,975}SE = 496 \pm 1.96 * 2$


- $IC_{95\%} = (492.08; 499.92)$



Evaluación de biomarcador

- Potencial biomarcador en imágenes de CT
- Muestra de 100 pacientes.

Estadístico	Mutado	No mutado
Media muestral	1,442	1,285
Desviación estándar	0,578	0,694
N	50	50





¿Esta diferencia puede deberse al azar (variabilidad de la muestra)?

Prueba de Hipótesis: ejemplo 2

- ¿El valor del biomarcador es mayor (diferente) en los pacientes con gen mutado?
- **Hipótesis nula:**
 - $\mu_1 = \mu_2$
- **Hipótesis alternativa:**
 - $\mu_1 \neq \mu_2$
- **Nivel de significancia (1 - alfa):**
 - 1%, 3%, 5%, 10%?



Hipótesis nula



Prueba de Hipótesis: ejemplo 2

Hipótesis alternativa

- ¿El valor del biomarcador es mayor en los pacientes con gen mutado?
- **Hipótesis nula:**
 - $\mu_1 = \mu_2$
- **Hipótesis alternativa:**
 - $\mu_1 \neq \mu_2$
- **Nivel de significancia (1 - alfa):**
 - 1%, 3%, 5%, 10%?



Prueba de Hipótesis: ejemplo 2

- Diferencia obs

- $\mu_1 - \mu_2 =$


- $\mu_1 - \mu_2 =$

- El grupo c
0.157 unid

- Error estándar

- $SE = \sqrt{\frac{s^2}{n}}$

- $SE = \sqrt{\frac{0.4105}{n}}$



Que prueba elegir:





Fig. 3—Flowchart shows appropriate choice of statistical test when comparing continuous variables between groups. ANOVA = analysis of variance.

**Me thinking
about being a
data scientist**



**Me studying to
become a data
scientist**



Vamos a python a trabajar con datos!!!!